

Cruzar el valle de la coordinación: gestores jerárquicos sobre opciones para tácticas de dos frentes en un juego depredador–defensa con drones

Bernardo Ordás Cernadas
Grado en Ingeniería Matemática e Inteligencia Artificial
Universidad Pontificia Comillas
Madrid, España
202214793@alu.comillas.edu

Resumen—Estudiamos la emergencia de tácticas coordinadas de dos frentes en una simulación 2D de protección de ganado: una manada de lobos ataca un rebaño defendido por drones. Una defensa no letal eficaz tiene un doble beneficio: los ganaderos dejan de perder reses y, al desaparecer el daño, desaparece el principal incentivo del control letal del depredador, reduciendo las muertes de lobos por represalia y favoreciendo la coexistencia. La táctica clave del atacante —el *cebo*, en la que un lobo se expone para arrastrar a la defensa mientras el grueso ataca el flanco opuesto— exige atravesar un valle de recompensa: dividir la manada empeora el retorno durante miles de pasos antes de que el engaño dé fruto. Mostramos empíricamente que el aprendizaje por refuerzo plano no cruza ese valle en ninguno de los dos bandos, y que las variantes residuales que parten de la táctica programada la *erosionan*. Proponemos una arquitectura jerárquica minimalista —un gestor PPO que elige entre opciones scripted congeladas, formulado como semi-MDP con terminación por eventos y un coste de deliberación— y la aplicamos simétricamente a ambos bandos. El gestor atacante converge en 3 de 3 entrenamientos independientes a la misma política en el estrato difícil ($P(\Delta 90 | S) = 1,000$), redescubriendo desde recompensa pura la estrategia destilada manualmente, con no-inferioridad al oráculo experto reproducida en réplica. El gestor defensor aprende a repartir efectivos ante un segundo frente y reduce las pérdidas frente a la barrera clásica en un factor 3–4 en las tres condiciones evaluadas. Documentamos además, como resultado metodológico, tres episodios de *specification gaming* detectados mediante pre-registro y auditoría conductual humana.

Index Terms—aprendizaje por refuerzo multiagente, aprendizaje jerárquico, opciones, semi-MDP, coordinación, specification gaming, enjambres de drones, coexistencia con depredadores

I. INTRODUCCIÓN

La depredación de ganado por lobos es un conflicto persistente allí donde ambos coexisten, y su gestión habitual —compensaciones a posteriori y control letal del depredador— es cara para el ganadero y letal para el lobo. Una defensa activa *no letal* basada en drones ataca el problema por ambos lados: si el rebaño no sufre bajas, el ganadero no pierde y el incentivo de la represalia desaparece. Este trabajo parte de una simulación 2D validada de ese escenario y de un resultado previo del propio proyecto: una defensa aprendida por refuerzo (MARL) supera a una barrera clásica de reglas fijas en pilotaje fino (0,77 frente a 0,93 reses perdidas por episodio). La pregunta central es si la coordinación táctica de

dos frentes —el cebo del atacante y el reparto de efectivos del defensor— puede aprenderse, o queda fuera del alcance del RL plano.


La táctica de interés es el **cebo de dos frentes** (Fig. 1): un lobo solitario se deja ver por un flanco para atraer a la barrera de drones, mientras la manada ataca por el flanco opuesto, que queda descubierto. Es coordinación de roles con sacrificio: el señuelo renuncia a cazar para que los demás maten. Nuestra hipótesis, confirmada por los experimentos, es que esta táctica está separada del comportamiento codicioso por un **valle de recompensa**: dividir la manada reduce las muertes a corto plazo (se pierde el quórum de caza en cada frente) durante miles de pasos antes de que el engaño compense. Un optimizador que mejora paso a paso llega al borde del valle, observa que separarse empeora, y retrocede: la patología conocida como *relative overgeneralization* [1], [2], aquí en su variante temporal, puesto que persiste incluso con una política centralizada de equipo.

Las contribuciones son cuatro:


1. **Diagnóstico**: evidencia sistemática de que el RL plano no cruza el valle en ninguno de los dos bandos: ocho campañas de ataque (PPO puro, con shaping potencial [3], warm-start por clonación, residuales sobre el script [4] y currículos) no hacen emerger el cebo, y las residuales lo *erosionan*; del lado defensor, 20M de pasos de MAPPO con libertad de movimiento no producen reparto entre frentes (Sec. V-A).
2. **Arquitectura**: un gestor jerárquico minimalista —PPO sobre un espacio discreto de opciones scripted congeladas, semi-MDP con terminación por eventos y coste de deliberación— implementable sobre Stable-Baselines3 [5] sin librerías adicionales (Sec. IV).
3. **Resultados simétricos**: el gestor atacante converge al mismo óptimo en 3/3 entrenamientos independientes y es no-inferior al oráculo experto (reproducido en réplica); el gestor defensor aprende el reparto condicional y reduce las pérdidas de la barrera clásica en factor 3–4 (Sec. V).
4. **Metodología**: un protocolo de pre-registro, semillas emparejadas y auditoría conductual humana que detectó

Jugada entera del manager lobo (seed 98, mixto, estrato S, opción $\Delta 90$): staged 901 → show 1231 → suelta 1419 → golpe 2375; sev 2

(a) show — $t = 1231$



(b) suelta — $t = 1419$



(c) golpe — $t = 2375$




Figura 1. La jugada completa aprendida por el gestor atacante (semilla 98, estrato disperso, opción $\Delta 90$ sostenida): (a) el señuelo se muestra y la barrera se ancla a él ($t=1231$); (b) suelta del asalto por el flanco opuesto ($t=1419$); (c) golpe ($t=2375$). Una única decisión de alto nivel ejecutada de principio a fin.

y cerró tres episodios de *specification gaming* [6] y cinco defectos del entorno antes de que contaminaran las conclusiones (Secs. III-E y V-D).

II. TRABAJO RELACIONADO

El valle de coordinación. La *relative overgeneralization* —converger a equilibrios subóptimos porque las acciones coordinadas parecen peores bajo el comportamiento actual de los compañeros— se ha atacado desde tres familias. La *exploración dirigida* usa novedad conjunta para forzar la visita al otro lado del valle (JIM [7], EMC [8]). Las *actualizaciones optimistas o lenientes* modifican la regla de aprendizaje para no castigar prematuramente las acciones cooperativas [2], [9]. La tercera familia, a la que pertenece este trabajo, *reestructura jerárquicamente* el espacio de decisión para que la maniobra coordinada cueste una elección discreta en lugar de una co-reografía de miles de pasos: las dos primeras familias *vadean* el valle; la jerarquía lo *puntea*.

Jerarquía y asignación en MARL. El marco de opciones y semi-MDP es clásico [10]; su aprendizaje end-to-end (Option-Critic [11]) sufre degeneración de opciones, y las jerarquías manager-worker con metas continuas (FeUdal [12], HIRO [13]) añaden maquinaria innecesaria cuando los roles son discretos y nombrables. Más cercanos a nuestro diseño son los asignadores centralizados de baja frecuencia sobre políticas de bajo nivel: COPA [14], ALMA [15] y HMASD [16]; y, en confrontación de enjambres, las capas de asignación discreta desacopladas de la ejecución continua [17]. Nuestra aportación respecto a esta línea no es el patrón asignador-ejecutor, sino su uso explícito para cruzar un valle de recompensa con pago diferido —una asignación *anti-codiciosa*— y su demostración simétrica en atacante y defensor del mismo entorno, con réplicas y pre-registro.

Dominio. El comportamiento de caza del paquete se inspira en el modelo de reglas simples de Muro *et al.* [18]; el pastoreo robótico parte de la heurística de Strömbom [19] y el pastoreo aéreo con RL jerárquico fue explorado por el grupo de Abbass [20]. En persecución-evasión, el MARL plano sí descubre coordinación espacial (flanqueos, divisiones)

cuando la recompensa es densa y monótona [21]; nuestro resultado delimita esa frontera: el plano reparte cuando repartir es monótonamente bueno, y falla cuando exige empeorar primero.

III. EL SISTEMA

III-A. Mundo

La simulación (NumPy, física congelada y versionada) transcurre en una parcela de 500×500 m con paso $dt = 0,1$ s y episodios de hasta 23 570 ticks (Fig. 2). Intervienen 4 drones activos más 4 de reserva con relevos por batería, 6 vacas adultas con 0–2 terneros, y entre 1 y 5 lobos por episodio que entran por el perímetro en uno o dos grupos angularmente separados ($\geq 60^\circ$). Velocidades máximas: dron 15 m/s, lobo 4 m/s, vaca 1,2 m/s. Una adulta muere si ≥ 2 lobos simultáneos la flanquean a ≤ 3 m fuera de su cono frontal; un ternero, con un solo lobo que evada a su defensora.

III-B. Percepción asimétrica y disuasión

Los lobos son omniscientes (modelo de adversario); la defensa solo conoce lo que percibe: *detección* a ≤ 100 m de algún dron activo y *confirmación* de tipo a ≤ 40 m, con memoria de equipo. La disuasión es acústica: todo lobo a ≤ 20 m de un dron activo huye. Esta asimetría hace posible el cebo: la barrera clásica solo reacciona a amenazas confirmadas y ancla su línea al primer confirmado, dejando descubierto el flanco opuesto.

III-C. Defensas y ataque scripted

La *barrera clásica* patrulla en anillo estático alrededor del rebaño y, ante una confirmación, despliega una línea rígida de ranuras separadas 20 m frente al ancla. El *cebo scripted* implementa la táctica de dos frentes a mano (merodeo del señuelo fuera de alcance, aproximación oscura del asalto, disparo sincronizado) y sirve como referencia superior del ataque. Como regla defensiva intermedia usamos un *asignador proporcional*: ante un segundo clúster de amenazas, destaca $\min(n_{\text{lobos}}, 2)$ guardias y mantiene el resto en línea.




Figura 2. Esquema del entorno: parcela de 500×500 m con establo central, estación de carga, rebaño y radios de percepción/disuasión del dron (expulsión 20 m, confirmación 40 m, detección 100 m). Posiciones ilustrativas.

III-D. Relevos, estación y huecos deliberados

La autonomía de batería obliga a relevos periódicos con la reserva. El protocolo final es de *centinela*: cada puesto de la formación y cada plaza de la estación de carga son posiciones fijas; el dron saliente avisa y permanece clavado en su puesto (quieto disuade igual), el entrante vuela directamente a esas coordenadas y el traspaso ocurre a ≤ 2 m; el saliente regresa a la plaza que su relevo dejó reservada. “Uno sale, uno entra, misma posición”: ningún otro dron se recoloca. En patrulla, el anillo adapta su radio a la dispersión del rebaño ($\approx 69\text{--}97$ m), lo que con cuatro efectivos fija la separación entre vecinos en $D = 2R \sin(\pi/4) \approx 1,41R$: la cobertura estricta de vigilancia ($D \leq 100$ m) es geoméricamente inalcanzable, pero la regla dura de no abrir pasillos ciegos ($D \leq 2r_{\text{det}} = 200$ m) se cumple en todo el corpus auditado. Los huecos restantes son *deliberados*: la línea cubre el frente del ancla y deja flancos y espalda abiertos —el objetivo del cebo—; y el *reflejo de investigación* (ante una detección, el activo libre más cercano acude a mirar) retira temporalmente un dron del anillo. El único episodio del corpus con entradas no detectadas combinó ambas cosas: un lobo solitario arrastró al investigador, el paquete entró por el arco debilitado y la escolta llegó 17 ticks tarde a una pérdida total; el fenómeno desapareció bajo v3.7, pero ilustra por qué la asignación de efectivos es la decisión defensiva crítica.

III-E. Cronología de ingeniería dirigida por auditoría

El entorno atravesó cuatro revisiones (v3.4→v3.7), todas originadas en el visionado humano de episodios renderizados y convertidas después en tests de regresión; las destacamos

porque cada una alteró conclusiones que los tests automáticos daban por buenas:

1. *Regla del sonido* (v3.5). El visionado reveló lobos cruzando la barrera por el punto medio entre dos drones, donde las fuerzas de repulsión se cancelaban y la expulsión —condicionada a que el dron se aproximara— no se activaba. Se redefinió la disuasión como campo siempre activo (≤ 20 m de cualquier dron). La consecuencia fue mayor: la ventaja de la defensa MARL previa se evaporó al corregir (había aprendido, en parte, a explotar el defecto) y toda la escalera de comparación se re-midió y re-entrenó.
2. *Patrulla estática* (v3.6). Los relevos contra puestos en órbita fallaban con frecuencia (persecución del punto de traspaso); con el sonido siempre activo, un dron quieto disuade igual que uno en movimiento, así que la órbita ya no aportaba nada. La espera de relevo cayó de 298 a 102 ticks y los drones varados, a cero.
3. *Relevo centinela* (v3.7). Al fijar puestos y plazas de carga (“uno sale, uno entra, misma posición”), se destapó que la patrulla llevaba desde v3.0 rotando silenciosamente a todos los drones una ranura en cada relevo —movimiento no ordenado sobre el que, sin saberlo, se apoyaban garantías del guion de ataque, que hubo que reformular a semántica de mejor esfuerzo. Principio destilado: ningún comportamiento debe apoyarse en movimiento no ordenado.
4. *Auditoría de cobertura*. La regla de diseño resultante —dos vecinos de formación no deben abrir un pasillo sin cobertura— se formalizó ($D \leq 2r$; con M drones en anillo de radio R , $D = 2R \sin(\pi/M)$, de modo que el listón estricto exigiría $M=6$) y su auditor detectó el único modo de entrada no detectada del corpus: el reflejo de investigación retira un dron del anillo y abre el arco vecino, un defecto de asignación de recursos de la defensa clásica que desapareció bajo v3.7.

Cada corrección se versionó, re-midió y re-congeló antes de continuar (Sec. IV-D); el determinismo bit a bit del simulador permitió verificar cada cambio con semillas emparejadas.

IV. MÉTODO

IV-A. Línea base plana

Del lado defensor, MAPPO [22] con actores compartidos y crítico centralizado (CTDE), acción residual continua sobre la barrera [4]. Del lado atacante, PPO [23] de cerebro único (una política mueve los 5 lobos), en variantes: recompensa rala pura, shaping potencial [3], warm-start por clonación de comportamiento, y residual sobre el script con y sin currículo de separación angular y sobremuestreo de episodios de dos frentes.

IV-B. Arquitectura jerárquica

Capa de opciones. Los comportamientos scripted existentes se encapsulan como opciones parametrizadas y congeladas. Atacante: MASA (caza codiciosa) y CEBO(Δ) —señuelo más asalto por el rumbo actual (*keep*) o desplazado $90^\circ / 180^\circ$ —,

con reglas de caza uniformes para todos los brazos (persistencia de presa, con re-selección solo si la presa está protegida, histéresis y cooldown). Defensor: despliegues {4-0, 3-1, 2-2} que reparten los cuatro puestos entre línea y guardias que persiguen al clúster secundario. La opción CEBO encapsula la coreografía completa como máquina de estados: designación del señuelo (el lobo de índice más bajo), aproximación oscura del asalto por un anillo exterior de ≈ 150 m, merodeo del señuelo fuera de alcance (> 130 m del dron más cercano), exhibición con “ala rota”, espera al compromiso de la barrera y suelta sincronizada; un emparejador determinista traduce la decisión del gestor en membresías, de modo que la elección de alto nivel es genuinamente de un solo paso.

Gestor semi-MDP. Un gestor por bando (PPO, red [64, 64], $\gamma = 1$ episódico) observa un resumen táctico de ~ 35 –40 rasgos invariantes a permutaciones (clústeres de amenazas y su separación angular, apertura por octantes, rasgos de progreso del engaño, estado del rebaño y reloj; el gestor defensor solo ve contactos y confirmados) y elige una opción. La opción retiene el control hasta un *evento terminal* (muerte, resolución del golpe, rebaño a salvo, aborto pre-disparo o techo de 4500 ticks): terminación por eventos en lugar de reloj fijo. Cada interrupción voluntaria de una opción en curso paga un *coste de deliberación* $\varepsilon = 0,05$ en la recompensa, que penaliza el churn estratégico sin prohibir ninguna decisión: el gestor conserva libertad total y debe ganarse cada cambio de plan. Para el atacante, la observación incluye estructura propia (vivos, número de clústeres y su separación angular —el rasgo que separa los estratos—), defensa (distancia de “puerta” por octante, fracción de activos en el cono del señuelo y desplazamiento proyectado de la barrera: los ingredientes continuos del progreso del engaño), rebaño y reloj de escolta; para el defensor, clústeres de contactos $\cup$ confirmados con memoria temporal por octante y el despliegue propio vigente. El entrenamiento usa 120k macro-decisiones con 24 entornos paralelos (lr $3 \cdot 10^{-4}$, entropía recocida $0,02 \rightarrow 0,005$) y cuesta horas de CPU: un orden de magnitud menos que una campaña plana.

IV-C. Calibración previa de la capa (Etapa 0)

Antes de entrenar gestor alguno se calibró el sustrato con brazos forzados y semillas emparejadas. (i) *Impuesto de interfaz nulo*: la capa reproduce bit a bit el guion de MASA y clava la referencia del cebo scripted sobre las mismas 58 parejas de dos frentes (severidad idéntica 58/58): ejecutar la táctica a través de la interfaz no cuesta nada. (ii) *El margen del cebo como decisión*: $\Delta(\text{CEBO} - \text{MASA})$ en el estrato agrupado creció con cada corrección del mundo ($+0,43 \rightarrow +0,85 \rightarrow +1,16$ de v3.4 a v3.6) y el estrato disperso cambió de signo al pasar a patrulla estática ($\Delta 90$: $-0,44 \rightarrow +0,32$), hasta las celdas limpias v3.7 de la Sec. V. (iii) *Latencias*: el percentil 75 del tiempo hasta el compromiso de la barrera (2,3–4,3 mil ticks) superó el umbral pre-registrado de 2000 ticks, disparando —dos veces, en dos mundos— la regla que eligió la terminación por eventos frente al reloj fijo. (iv) *Frontera de quórum*: con $n \leq 2$ lobos la caza contra la defensa real

es residual (0,15–0,18 muertes/episodio), de modo que el entrenamiento muestrea $n \in \{3, 4, 5\}$ y la evaluación mantiene la distribución natural completa.

IV-D. Protocolo experimental

Todos los experimentos usan **semillas emparejadas** (mismo episodio, distinta política) con intervalos por bootstrap (10^4 remuestreos) sobre las diferencias por semilla, típicamente con 100–400 pares por celda. Antes de cada entrenamiento se congela un **pre-registro** con los listones de las líneas base re-medidos y un criterio de éxito compuesto: *estructura* (la política discrimina el estado: cebar donde compensa, repartir ante el segundo frente) más *no-inferioridad* frente al oráculo destilado ($\delta = 0,15$). Cada hito pasa por tres firmas en orden: aserciones automáticas, **visionado humano** de episodios renderizados seleccionados por criterio, y análisis numérico. Se registra además una métrica de *censura* —si la jugada llegó a jugarse— para distinguir un cero sin jugar de un cero jugando y fallando; esta métrica destapó dos interbloqueos de la propia capa jerárquica (Sec. V-D).

Como oráculo atacante usamos la regla destilada de la calibración previa (CEBO si $n \geq 3$, con *keep* en spawn agrupado y $\Delta 90$ en disperso; MASA en caso contrario); como listón defensor, el asignador proporcional. Todos los artefactos (pre-registros con marca temporal, evaluaciones, líneas temporales de eventos, episodios renderizados y checkpoints) quedan archivados con manifiesto y hashes, y cada mundo está etiquetado (v3.4–v3.7): cualquier cifra de este artículo es reproducible con su semilla.

V. RESULTADOS

V-A. El RL plano no cruza el valle

Del lado atacante, ninguna de las ocho campañas planas hizo emerger el cebo (Tabla I). Desde cero no hay señal (una o dos muertes espontáneas en $\approx 2\,300$ episodios, 2,48M pasos); con shaping y warm-start, el mejor resultado queda en 0,57–0,72 muertes/episodio frente a un suelo scripted de 2,77 en el mismo arnés (v2.4.1); y en el mundo v3.4, las variantes residuales —que *parten* del cebo programado— no superan el suelo (2,17–2,71 frente a 2,68) y lo degradan de forma reproducible: la firma del canal trasero del cebo (fracción de matadores nunca confirmados, KNC) cae del 26,6% al 13% a lo largo del entrenamiento. El gradiente local en el óptimo apunta hacia fuera de la táctica. Del lado defensor, el MAPPO residual mejora el pilotaje (Sec. V-C) pero el reparto entre frentes no emerge en 20M de pasos (5,7% $\rightarrow$ 5,3% de episodios con división).

La Fig. 3 materializa la causa: forzando la táctica mediante la capa de opciones, las muertes acumuladas del cebo van *por debajo* de la masa hasta el tick $\approx 2\,100$ (v3.5; $\approx 4\,700$ en v3.4) y solo cruzan en la cola del episodio. Ese tramo negativo de miles de pasos es el valle que el descenso por gradiente no atraviesa y que la erosión residual confirma desde el otro borde.

Tabla I
LAS OCHO CAMPAÑAS PLANAS DEL BANDO ATACANTE.

Runs	Enfoque	Resultado
01	PPO, recompensa mala	sin señal (1–2 muertes en $\approx 2\,300$ eps)
02	+ shaping potencial	0,57
03	+ clonación (warm-start)	0,65–0,72
04	residual sobre el script	$\approx$ suelo; sin táctica nueva
05–06	+ currículo de separación	erosión del cebo
07–08	+ dieta de dos frentes	2,17–2,71 $\leq$ suelo 2,68; KNC 26,6 % $\rightarrow$ 13 %




Figura 3. El valle de recompensa medido: muertes acumuladas medias del cebo frente al ataque en masa (estrato agrupado, semillas emparejadas). La táctica rinde por debajo durante miles de ticks antes de superarla; cruce $\approx 2\,100$ en v3.5 (trazo continuo) y $\approx 4\,700$ en v3.4 (punteado).

V-B. Gestor atacante: invariante y no-inferioridad

La Tabla II resume la escalera de comparación en el mundo final (v3.7), con listones congelados por pre-registro antes del entrenamiento. El gestor supera a todas las reglas fijas y es no-inferior al oráculo destilado, con una ventaja puntual de $+0,10$ [$+0,03$, $+0,19$] en el run principal; la réplica con semilla distinta reproduce el núcleo ($1,69$ [$1,38$, $2,01$]; $+0,03$ [$-0,12$, $+0,18$] frente al oráculo, dentro de δ).

El resultado central no es el margen sino el **invariante de convergencia**: en los tres entrenamientos independientes (run principal, ablación de terminación fija y réplica), la política converge a la misma elección en el estrato de spawn disperso, $P(\Delta 90 | S) = 1,000$ (Fig. 4), coincidente con el mejor brazo del paisaje medido en celdas forzadas (MASA $0,30$ / $\Delta 90$ $1,71$ [$1,29$, $2,14$] / $\Delta 180$ $1,42$). El gestor redescubre desde recompensa pura, sin regla alguna que se la dicte, la estrategia que la calibración experimental había destilado manualmente. En el estrato agrupado, la elección varía entre semillas (*keep* en el run principal, $\Delta 180$ en ablación y réplica) sin diferencia apreciable de rendimiento entre runs, lo que apunta a un paisaje aproximadamente plano entre ambas alternativas: la política converge exactamente allí donde el paisaje distingue y fluctúa donde no hay nada que aprender. La política transfiere

Tabla II
ESCALERA DEL BANDO ATACANTE (RESES DEPREDADAS/EPISODIO; MÁS ES MEJOR PARA EL ATACANTE; 100 SEMILLAS EMPAREJADAS, DEFENSA: BARRERA CLÁSICA V3.7).

Política	Sev.	Δ vs oráculo [IC 95 %]
MASA siempre	0,56	—
Cebo si spawn agrupado	0,95	—
Oráculo destilado	1,66	—
Gestor (run principal)	1,76	$+0,10$ [$+0,03$, $+0,19$]
Gestor (réplica)	1,69	$+0,03$ [$-0,12$, $+0,18$]

Tabla III
BANDO DEFENSOR (RESES PERDIDAS/EPISODIO; MENOS ES MEJOR; 100 SEMILLAS EMPAREJADAS POR CELDA Y RUN; Δ CONJUNTOS SOBRE 200 PARES).

Defensa	Natural	Cebo scripted	Gestor atacante
Barrera clásica 4-0	0,74	2,61	1,76
Proporcional scripted	0,25	0,85	0,61
Gestor (run ppal.)	0,21	1,03	0,67
Gestor (réplica)	0,21	1,06	0,76
Δ conj. vs 4-0	-0,53	-1,56	-1,05
Δ conj. vs prop.	-0,04 [$-0,10$, $0,01$]	+0,20 [$0,07$, $0,33$]	+0,10 [$0,02$, $0,19$]

sin degradación a dos defensas aprendidas nunca vistas en entrenamiento ($1,75/1,76$), y su disciplina de decisión es la prevista por diseño: 3,5 decisiones/episodio, jugada completa en el 100 % de los episodios, abortos residuales $0,28$ /episodio y coste de deliberación pagado ≈ 0 .

La ablación con terminación fija ($K = 1\,000$ ticks) aprendió la misma estructura pero con margen degradado y $\approx \times 3,25$ de cómputo: la terminación por eventos resultó ser *ingrediente del margen, no del mecanismo* —la predicción fuerte pre-registrada (colapso) falló, y así se reporta—; lo que cruza el valle es la abstracción temporal estructural: que la opción exista y ejecute la jugada entera. La réplica reprodujo además la disciplina (abortos $0,46$ /episodio, jugada completa $95,5$ %) y la ablación mantuvo $P(\Delta 90 | S) = 1,000$ pese al reloj fijo: tres optimizaciones independientes, tres llegadas al mismo punto del estrato que discrimina.

V-C. Gestor defensor: el reparto emerge y se reproduce

El gestor defensor aprende el reparto condicional y lo reproduce en réplica: $P(\text{guardias} | 2^\circ \text{ clúster}) = 1,000$ y $0,943$ en los dos runs, con 4-0 mayoritario ante un solo frente y latencias de reparto de decenas de ticks. Frente a la barrera clásica reduce las pérdidas en las tres condiciones con intervalos que excluyen el cero (Tabla III), y el canal trasero del cebo queda cerrado (KNC = 0 en las celdas natural y de cebo), con los guardias ganando la carrera de redespliegue en el 78 – 89 % de los episodios. Frente al asignador proporcional es no-inferior en mezcla natural, marginal frente al atacante adaptativo, y *pierde de forma reproducida* frente al cebo scripted ($+0,20$ [$+0,07$, $+0,33$] conjunto): contra un atacante rígido que siempre ejecuta el mismo patrón, una regla fija afinada a ese patrón sigue siendo superior; contra el atacante adaptativo —el relevante—, el aprendido la iguala. Dos hallazgos no anticipados: el gestor *prácticamente nunca* usa el despliegue 3-1 previsto




Figura 4. (a) Política final del gestor atacante: probabilidad de la primera opción por estrato de spawn y número de lobos (*keep* en agrupado 0,89–1,00; $\Delta 90$ en disperso 1,00 para todo n). (b) Curva de emergencia durante el entrenamiento (evaluación ligera, 40 semillas).




Figura 5. Trade-off cobertura/reparto: penetraciones de la línea frente a severidad, por defensa y tipo de atacante. Repartir compra el segundo frente al precio de adelgazar el primero.

en el diseño (0,000 y 0,019 en los dos runs) y reparte siempre a 2-2, una preferencia ausente de todas nuestras reglas; y el reparto tiene precio medido: la línea de dos drones sufre más penetraciones (Fig. 5), consecuencia directa de la geometría acústica (20 m por dron). La disciplina del gestor acompaña: 1,2 reasignaciones/episodio frente a las 22 de la proporcional (sin parpadeo de despliegue), latencias de reparto de 10–104 ticks según run y semilla, coste de deliberación pagado 0,014–0,019, y un patrón de *guardias preventivos* en episodios tranquilos (147–189 de 400 episodios con guardias destacados sin segundo frente confirmado): un seguro aprendido contra la distribución de entrenamiento —mezcla natural más gestor atacante— que en la celda natural apenas cuesta (es la mejor cifra de esa columna) y se reporta sin optimizar.

Comparando los dos niveles de aprendizaje defensivo: el

pilotaje fino aprendido (MAPPO residual) mejora a la barrera en $\sim 0,2$ (0,77 vs 0,93), mientras que la asignación aprendida la mejora en 0,5–1,6 según el atacante: el margen residía en la coordinación de alto nivel, no en el control de bajo nivel.

V-D. Specification gaming como resultado de proceso

El protocolo detectó tres episodios en los que el gestor optimizaba resquicios de la interfaz en lugar de la táctica, todos invisibles para los tests automáticos y descubiertos por la combinación de compuertas pre-registradas y visionado humano: (i) *re-selección de presa*: re-arrancar opciones reelegía la presa del asalto, convirtiendo el churn de decisiones en un volante de re-apuntado que la barrera no podía seguir (ventaja inflada de +0,42); se resolvió legalizando la capacidad —cambiar de presa es caza realista— pero regulada con condición de caza e igual para todos los brazos de comparación; (ii) *molinillo de rumbo*: un evento de aborto mal especificado sonaba en bucle tras el disparo y permitía rotar el asalto más rápido de lo que la barrera re-anclaba (45 interrupciones/episodio); el coste de deliberación más la corrección del evento lo redujeron a 0,28, y el análisis forense reveló que parte de aquel margen consistía en *desatascar* dos interbloqueos de la propia capa (un requisito de rumbo de $\pm 25^\circ$ y una meseta de aproximación) que dejaban al oráculo sin jugar en 9 de 20 episodios del estrato disperso —en el peor caso, el episodio completo (23 570 ticks) esperando una señal geométricamente imposible—, corregidos a semántica de mejor esfuerzo; (iii) el episodio testigo (semilla 21) resume la trayectoria completa: 7 muertes con el primer exploit, 6 con el molinillo, 0 con el juego limpio. La lección generaliza: con un optimizador competente, cada condición de la interfaz es una regla del juego, y el pre-registro con auditoría conductual es lo que separa “aprendió la táctica” de “encontró el agujero”. Tres prácticas resultaron decisivas: convertir cada hallazgo visual en aserción de regresión (el orden del cebo, el corredor cerrado, el no-apilamiento); dejar *cables trampa* pasivos sobre los defectos aceptados (contadores que marcan el episodio y

lo envían a visionado si el optimizador reincide); y mantener una fe de erratas pública en la tabla maestra de artefactos (denominadores, redondeos dobles, atribuciones por semilla), de modo que ningún número se corrige en silencio.

VI. DISCUSIÓN Y LIMITACIONES

Por qué funciona la jerarquía. El valle no se cruza dando más libertad al nivel de movimiento —ocho campañas y 20M de pasos lo atestiguan— sino subiendo la decisión coordinada a un nivel donde probarla cuesta una elección: “empezar a cebar” pasa de coreografía improbable a una de cuatro acciones discretas, y el retorno de la opción completa hace visible el pago diferido. La terminación por eventos abarata además el crédito (el pago cae dentro de la opción que lo causó); la ablación muestra que sin ella la estructura aún emerge, pero con peor margen y triple coste.

Rígido frente a adaptativo. El único punto donde una regla fija supera al aprendizaje (defensa contra cebo scripted) es también el único con atacante de patrón fijo. La lectura conjunta es consistente: el aprendizaje compra adaptación —igual a la mejor regla donde el rival varía y aporta preferencias no contenidas en ninguna regla, como el reparto 2-2— y la regla compra especialización.

Hacia el campo. El simulador toma partido optimista en dos puntos que la transferencia real deberá revisar: la disuasión acústica siempre eficaz (los depredadores reales se habitúan a los disuasores estáticos, lo que sugiere alternar estímulos o reservar el sonido al contacto cercano) y la percepción de dos radios como oráculo geométrico, cuyo sustituto natural es un detector visual embarcado; la infraestructura comercial de collares de pastoreo virtual haría además plausible la escolta activa del rebaño. El doble beneficio que motiva el sistema —cero bajas y, con ello, cero represalias— depende de que estas simplificaciones sobrevivan al campo.

Limitaciones y trabajo futuro. (1) Un solo entorno, con opciones de bajo nivel congeladas: el ajuste fino conjunto (p.ej. residual bajo gestor) queda como trabajo futuro, con la erosión observada como riesgo documentado. (2) Los gestores se entrenaron contra oponentes congelados; la co-evolución de ambos bandos (entrenamiento alternado con oponentes fijos por fase) es la extensión natural, con la receta de fases semiestáticas: cada bando entrena contra el otro congelado y se evalúa contra una suite fija para evitar ciclos. (3) El gestor atacante es omnisciente por modelo de adversario. (4) El trade-off de penetraciones del reparto 2-2 y los guardias preventivos en episodios tranquilos están medidos pero no optimizados; la regla “proporcional-2-2” destilada del propio gestor es candidata a nuevo listón. (5) La cobertura estricta de vigilancia en patrulla es geométricamente inalcanzable con 4 drones ($D = 2R \sin(\pi/M)$): más efectivos o anclaje a la res más expuesta son mejoras naturales. (6) Números de un solo simulador propio; el código, las semillas y los artefactos publicados permiten la reproducción exacta (determinismo bit a bit verificado). (7) No comparamos empíricamente contra las familias de exploración dirigida u optimismo (Sec. II); la

comparación es conceptual y su implementación queda como trabajo futuro.

VII. CONCLUSIÓN

En un juego depredador-defensa con drones, la táctica de dos frentes está separada del comportamiento codicioso por un valle de recompensa que el RL plano no cruza en ninguno de los dos bandos. Un gestor jerárquico mínimo —PPO sobre opciones scripted congeladas, semi-MDP con terminación por eventos y coste de deliberación— lo cruza en ambos: el atacante redescubre la estrategia experta con un invariante de convergencia en 3/3 entrenamientos y no-inferioridad replicada; el defensor aprende el reparto condicional y multiplica por 3–4 la eficacia de la barrera clásica, acercando la meta práctica que motiva el sistema: rebaños sin bajas y, con ello, lobos sin represalias. El mismo protocolo que produjo estos números detectó tres episodios de specification gaming y cinco defectos del entorno antes de que contaminaran las conclusiones: en presencia de un optimizador, la metodología no es acompañamiento del resultado; es parte del resultado.

REFERENCIAS

- [1] L. Panait and S. Luke, “Cooperative multi-agent learning: The state of the art,” *Autonomous Agents and Multi-Agent Systems*, vol. 11, no. 3, pp. 387–434, 2005.
- [2] E. Wei and S. Luke, “Lenient learning in independent-learner stochastic cooperative games,” *Journal of Machine Learning Research*, vol. 17, no. 84, pp. 1–42, 2016.
- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *Proceedings of the 16th International Conference on Machine Learning (ICML)*, 1999.
- [4] T. Silver, K. Allen, J. Tenenbaum, and L. Kaelbling, “Residual policy learning,” *arXiv preprint arXiv:1812.06298*, 2018.
- [5] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dornmann, “Stable-baselines3: Reliable reinforcement learning implementations,” *Journal of Machine Learning Research*, vol. 22, no. 268, pp. 1–8, 2021.
- [6] B. Baker, I. Kanitscheider, T. Markov, Y. Wu, G. Powell, B. McGrew, and I. Mordatch, “Emergent tool use from multi-agent autocurricula,” in *International Conference on Learning Representations (ICLR)*, 2020.
- [7] M. Toquebiau, N. Bredeche, F. Benamar, and J.-Y. Jun, “Joint intrinsic motivation for coordinated exploration in multi-agent deep reinforcement learning,” *arXiv preprint arXiv:2402.03972*, 2024.
- [8] L. Zheng, J. Chen, J. Wang, J. He, Y. Hu, Y. Chen, C. Fan, Y. Gao, and C. Zhang, “Episodic multi-agent reinforcement learning with curiosity-driven exploration,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [9] G. Palmer, K. Tuyls, D. Bloembergen, and R. Savani, “Lenient multi-agent deep reinforcement learning,” in *Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems (AAMAS)*, 2018.
- [10] R. S. Sutton, D. Precup, and S. Singh, “Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning,” *Artificial Intelligence*, vol. 112, no. 1-2, pp. 181–211, 1999.
- [11] P.-L. Bacon, J. Harb, and D. Precup, “The option-critic architecture,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2017.
- [12] A. S. Vezhnevets, S. Osindero, T. Schaul, N. Heess, M. Jaderberg, D. Silver, and K. Kavukcuoglu, “FeUdal networks for hierarchical reinforcement learning,” in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, 2017.
- [13] O. Nachum, S. Gu, H. Lee, and S. Levine, “Data-efficient hierarchical reinforcement learning,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [14] B. Liu, Q. Liu, P. Stone, A. Garg, Y. Zhu, and A. Anandkumar, “Coach-player multi-agent reinforcement learning for dynamic team composition,” in *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021, pp. 6860–6870.

- [15] S. Iqbal, R. Costales, and F. Sha, "ALMA: Hierarchical learning for composite multi-agent tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [16] M. Yang, Y. Yang, Z. Lu, W. Zhou, and H. Li, "Hierarchical multi-agent skill discovery," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [17] Q. Wu, K. Liu, L. Chen, and J. Lü, "Hierarchical reinforcement learning for swarm confrontation with high uncertainty," *IEEE Transactions on Automation Science and Engineering*, vol. 22, 2025, arXiv:2406.07877.
- [18] C. Muro, R. Escobedo, L. Spector, and R. P. Coppinger, "Wolf-pack (canis lupus) hunting strategies emerge from simple rules in computational simulations," *Behavioural Processes*, vol. 88, no. 3, pp. 192–197, 2011.
- [19] D. Strömbom, R. P. Mann, A. M. Wilson, S. Hailes, A. J. Morton, D. J. T. Sumpter, and A. J. King, "Solving the herding problem: heuristics for herding autonomous, interacting agents," *Journal of The Royal Society Interface*, vol. 11, no. 100, p. 20140719, 2014.
- [20] H. T. Nguyen, T. D. Nguyen, V. P. Tran, M. Garratt, K. Kasmarik, S. Anavatti, M. Barlow, and H. A. Abbass, "Continuous deep hierarchical reinforcement learning for ground-air swarm herding," *arXiv preprint arXiv:2004.11543*, 2020.
- [21] S. Xu and Z. Dang, "Emergent behaviors in multiagent pursuit evasion games within a bounded 2d grid world," *Scientific Reports*, vol. 15, no. 1, p. 29376, 2025.
- [22] C. Yu, A. Velu, E. Vinitzky, J. Gao, Y. Wang, A. Bayen, and Y. Wu, "The surprising effectiveness of PPO in cooperative multi-agent games," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [23] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," *arXiv preprint arXiv:1707.06347*, 2017.